어느 부분을 양자화하면 공격이 약해질까

SmolVLM-256M 부분별 양자화 실험 결과 분석

온디바이스 AI 7조 · 2026년 10월 10일 · 사진 3장으로 한 예비 실험이며, 모든 수치는 재현이 필요합니다.

1. 한눈에 보는 결론

사진에 눈에 보이지 않는 노이즈를 넣어, 모델이 말을 멈추지 못하게 만드는 공격이 있습니다. 이 공격 사진을 원본 모델로 만든 다음, 모델의 네 부분 중 **한 부분만** 양자화(숫자를 거칠게 반올림)한 모델에 넣어 보았습니다.

- **8비트**로 양자화하면 네 부분 중 어디를 바꿔도 공격이 그대로 통했습니다. 공격 사진 3장 모두 답이 상한인 512토큰까지 이어졌습니다.
- **4비트**로 양자화하면 **비전 인코더**(사진을 보는 부분)를 바꿨을 때만 공격이 약해졌습니다. 3장 모두 512토큰에 닿지 못하고 26, 24, 101토큰에서 답이 끝났습니다.
- 연결부, 언어모델, 출력층은 4비트로 바꿔도 3장 모두 공격이 유지됐습니다.



그림 1. 모델이 답을 만드는 순서와 부분별 결과. 부분 아래 숫자는 그 부분만 양자화했을 때, 공격 사진 3장 중 답이 상한(512토큰)에 닿은 사진 수입니다.

왜 이런 결과가 나왔나 (요약)

4비트는 숫자를 8비트보다 약 10배 크게 바꿉니다(약 1% 대 약 9~11%). 그런데 같은 4비트라도 결과가 달라진 것은 비전 인코더뿐이었습니다. 공격 노이즈의 효과가 만들어지는 곳이 비전 인코더이고, 여기에는 층이 72개나 이어져 있어 반올림 오차가 쌓이기 때문으로 보입니다. 나머지는 층이 하나뿐이거나(연결부, 출력층) 공격 신호가 이미 온전히 지나간 뒤의 부분(언어모델, 출력층)이라, 같은 크기의 오차로는 결과가 바뀌지 않았습니다.

2. 먼저 알아둘 것

2.1 모델이 사진을 보고 답하는 순서

SmolVLM은 사진과 질문을 받아 글로 답하는 모델입니다. 안에서는 네 부분이 차례로 일합니다.

순서	부분	비유	하는 일	양자화한 층
①	비전 인코더	눈	사진을 '그림 정보'라는 숫자 묶음으로 바꿉니다.	Linear 72개
②	연결부	통역사	그림 정보를 언어모델이 읽을 수 있는 형태로 바꿔 넘겨줍니다.	Linear 1개
③	언어모델	머리	그림 정보와 질문을 보고 다음에 올 말을 계산합니다.	Linear 210개
④	출력층	입	후보 토큰마다 점수를 매깁니다. 점수가 가장 높은 토큰이 다음 말이 됩니다.	Linear 1개

Linear 층은 숫자 여러 개를 곱하고 더하는 계산 한 번을 뜻합니다. 이번 실험에서 양자화한 것은 이 Linear 층들입니다.

2.2 답은 언제 끝나는가

- 모델은 답을 **토큰**(단어 조각) 단위로 하나씩 만듭니다.
- 토큰을 하나 만들 때마다 약 4만 9천 개의 후보에 점수를 매기고, 1등인 토큰을 고릅니다.
- 후보 중에는 '여기서 끝'을 뜻하는 **종료 토큰**이 있습니다. 종료 토큰이 1등이 되는 순간 답이 끝납니다.
- 이번 실험에서는 답이 512토큰이 되면 강제로 멈췄습니다. 그래서 512은 '끝까지 스스로 멈추지 않았다'는 뜻입니다.

2.3 공격이란

- 사진의 점(픽셀) 하나하나는 0부터 255 사이의 밝기 값을 갖습니다. 공격은 이 값을 최대 8만큼만 바꿉니다. 사람 눈에는 원본과 구별되지 않습니다.
- 이 작은 변화(노이즈)는 아무렇게나 넣은 것이 아닙니다. 원본 모델에서 종료 토큰의 점수가 계속 낮게 나오도록, 계산을 수십 번 되풀이해 다듬은 것입니다.
- 그 결과 모델은 '그만 말하기' 단추를 누르지 못하고 512토큰까지 말을 이어 갑니다. 답이 길어지는 만큼 계산과 전기를 더 씁니다.
- 예를 들어 곰 사진에 원본 모델은 "In this image we can see a bear."(10토큰)라고 답하고 멈춥니다. 같은 사진의 공격본에는 뜻이 통하지 않는 구절을 되풀이하며 512토큰까지 갑니다.

2.4 양자화란

- 모델은 약 2억 5천만 개의 숫자(가중치)로 이루어져 있습니다. 양자화는 이 숫자들을 미리 정한 몇 개의 값 중 가장 가까운 값으로 반올림해서 용량을 줄이는 방법입니다.
- **8비트는 256개**, **4비트는 16개**의 값만 씁니다. 자의 눈금이 촘촘한지 듬성듬성한지의 차이와 같습니다. 눈금이 듬성듬성할수록 원래 값과의 차이(오차)가 커집니다.
- 휴대폰 같은 작은 기기에는 보통 이렇게 양자화한 모델을 넣습니다. 그래서 '원본 모델로 만든 공격이 양자화한 모델에서도 통하는가'가 이 실험의 질문입니다.

3. 실험 방법

- 공격 사진 3장(곰, 고양이, 거실)을 원본 모델로 한 번 만들어 고정했습니다. 모든 경우에 같은 사진을 썼습니다.
- 네 부분 중 **한 부분만** 8비트 또는 4비트로 양자화하고, 나머지는 원본 그대로 두었습니다. 아무것도 양자화하지 않은 기준을 더해 모두 9가지 경우입니다.
- 경우마다 원본 사진과 공격 사진을 넣고 답의 길이(토큰 수)를 쟀습니다. 질문은 "Describe this image in one sentence." 하나입니다.
- 공격 사진의 답이 512토큰에 닿으면 '공격 유지'로 셌습니다.
- 답 길이만으로는 이유를 알 수 없어서, 모델 안의 값을 따로 쟀습니다. 측정 항목의 뜻은 아래 표와 같습니다.

측정 항목	뜻	읽는 법
가중치 변화	양자화로 그 부분의 숫자가 달라진 크기 ÷ 원래 크기	클수록 많이 바뀜
공격 방향 보존	언어모델로 들어가는 그림 정보에서, 공격이 만든 변화가 원본 모델에서와 같은 방향으로 남아 있는 정도	1이면 그대로, 0이면 무관
흔들림 비율	양자화가 그림 정보를 흔든 크기 ÷ 공격이 그림 정보를 바꾼 크기	0이면 안 흔들림
종료 점수 차	1등 토큰 점수 - 종료 토큰 점수. 기준 모델이 공격 사진에 낸 답의 앞 64토큰을 그대로 따라가게 하며 잰 평균	클수록 종료가 멂
문장 끝 종료 여유	문장이 끝나는 자리에서, 종료 토큰 점수 - 나머지 토큰 중 1등 점수	0보다 크면 거기서 끝냄, 작으면 더 말함

문장 끝 종료 여유는 두 자리에서 쟀습니다. 공격 사진은 '비전 인코더만 4비트' 모델이 답을 끝낸 자리, 원본 사진은 기준 모델이 답을 끝낸 자리입니다. 모든 모델에게 같은 문장을 그대로 따라가게 한 뒤, 그 자리의 점수만 비교했습니다.

4. 부분별 분석

표의 값은 '원본 사진의 답 길이 → 공격 사진의 답 길이'입니다. '측정으로 확인한 것'은 실제로 잰 값이고, '왜 그런가'는 그 값을 바탕으로 한 해석입니다.

4.1 비전 인코더 — 사진을 보는 '눈'

사진	기준 (양자화 없음)	비전 인코더만 8비트	비전 인코더만 4비트
곰	10 → 512	10 → 512	10 → 26
고양이	13 → 512	13 → 512	13 → 24
거실	17 → 512	19 → 512	18 → 101
공격 유지	3/3	3/3	0/3

측정으로 확인한 것

- 가중치는 8비트에서 0.96%, 4비트에서 9.42% 달라졌습니다.
- 원본 모델에서 공격은 그림 정보를 원래 크기의 62~71%만큼 바꿉니다. 눈에 보이지 않는 노이즈가 비전 인코더를 지나면서 크게 불어난다는 뜻입니다.
- 공격 방향 보존은 8비트에서 0.98~0.99, 4비트에서 0.74~0.81입니다. 4비트에서는 공격이 만든 변화가 원래 방향에서 벗어났습니다.

- 흔들림 비율은 8비트에서 0.15, 4비트에서 0.61~0.63입니다. 4비트의 반올림이 그림 정보를 흔든 크기가, 공격이 만든 변화의 절반을 넘습니다.
- 문장 끝 종료 여유는 4비트에서 +0.4 ~ +5.6로 종료 토큰이 1등입니다. 같은 자리에서 기준 모델은 -24.4 ~ -22.7로, 종료 토큰이 한참 뒤처져 있습니다(그림 3).

왜 그런가 (해석)

- 공격 노이즈는 원본 비전 인코더의 숫자에 정확히 맞춰 다듬은 것입니다. 자물쇠에 딱 맞게 깎은 열쇠와 비슷합니다.
- 4비트로 바꾸면 노이즈가 지나가는 72개 층의 숫자가 모두 약 9%씩 달라집니다. 층을 하나 지날 때마다 어긋남이 조금씩 쌓여, 마지막에 나오는 그림 정보에서는 공격이 의도한 변화가 흐트러집니다.
- 그러면 언어모델이 받는 '멈추지 마' 신호가 약해지고, 문장이 끝나는 자리에서 종료 토큰이 다시 1등이 됩니다.
- 8비트는 숫자가 약 1%만 달라져서 어긋남이 작습니다. 공격이 만든 변화가 거의 그대로 남아 공격이 유지됩니다.

> **결론** 비전 인코더에서 공격이 약해진 것은 '공격 노이즈가 지나가는 부분'을 '4비트로 거칠게' 반올림했기 때문으로 보입니다. 두 조건이 함께 있어야 했고, 8비트 정도의 반올림으로는 부족했습니다.

다만 4비트에서도 공격의 영향이 모두 사라지지는 않았습니다. 공격 사진의 답(26, 24, 101토큰)은 원본 사진의 답(10, 13, 18토큰)보다 길었고, "harley davidson", "boombox"처럼 사진에 없는 내용이 섞여 있었습니다.

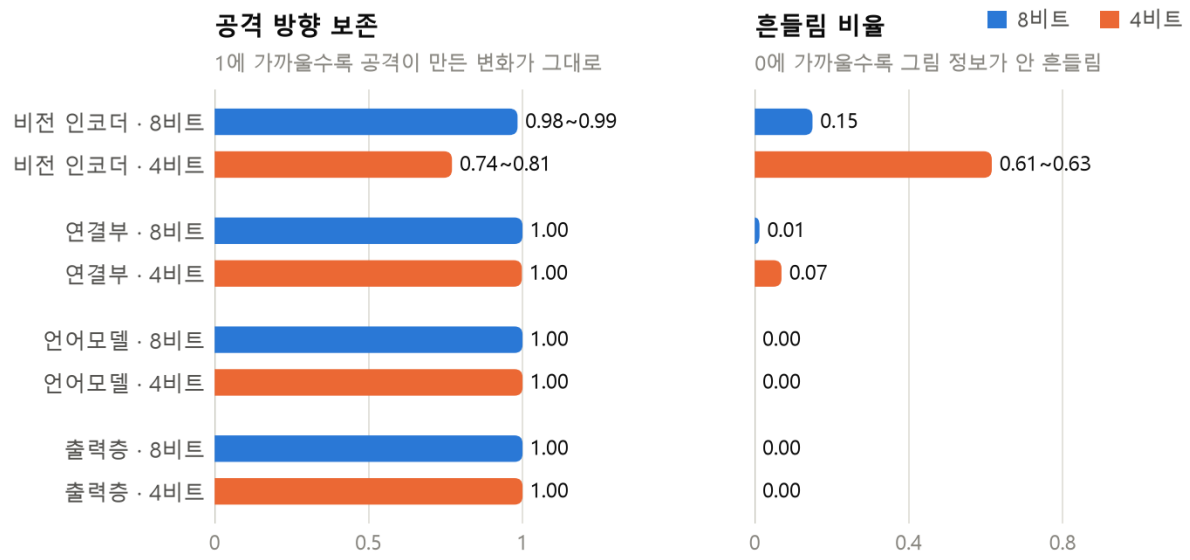


그림 2. 언어모델로 들어가는 그림 정보에 공격이 얼마나 남았나. 막대는 사진 3장의 평균, 숫자는 3장의 범위입니다. 언어모델과 출력층은 비전 인코더와 연결부를 건드리지 않으므로 그림 정보가 기준과 같습니다.

4.2 연결부 — 그림 정보를 넘겨주는 '통역사'

사진	기준 (양자화 없음)	연결부만 8비트	연결부만 4비트
곰	10 → 512	10 → 512	10 → 512
고양이	13 → 512	13 → 512	13 → 512
거실	17 → 512	22 → 512	17 → 512
공격 유지	3/3	3/3	3/3

측정으로 확인한 것

- 가중치는 8비트에서 0.97%, 4비트에서 9.21% 달라졌습니다. 비전 인코더와 같은 수준입니다.
- 그런데 공격 방향 보존은 두 경우 모두 1.00이고, 흔들림 비율은 8비트 0.01, 4비트 0.07에 그쳤습니다.
- 문장 끝 종료 여유도 -24.3 ~ -22.4로 기준과 같습니다.

왜 그런가 (해석)

- 연결부는 층이 하나뿐입니다. 반올림 오차가 한 번 생기고 끝나서, 비전 인코더처럼 쌓일 곳이 없습니다.
- 그래서 숫자가 약 9% 달라져도 그림 정보는 조금만 흔들립니다. 공격이 그림 정보에 만든 변화(원래 크기의 62~71%)에 비하면 훨씬 작습니다.

> **결론** 연결부는 4비트로 양자화해도 공격 신호가 거의 그대로 지나갑니다. 층이 하나라 오차가 쌓이지 않기 때문으로 보입니다.

4.3 언어모델 — 다음 말을 생각하는 '머리'

사진	기준 (양자화 없음)	언어모델만 8비트	언어모델만 4비트
곰	10 → 512	10 → 512	13 → 512
고양이	13 → 512	13 → 512	10 → 512
거실	17 → 512	29 → 512	17 → 512
공격 유지	3/3	3/3	3/3

측정으로 확인한 것

- 가중치는 8비트에서 0.85%, 4비트에서 9.35% 달라졌습니다.
- 언어모델로 들어오는 그림 정보는 기준과 완전히 같습니다(흔들림 비율 0.00, 공격 방향 보존 1.00). 비전 인코더와 연결부를 원본 그대로 두었기 때문입니다.
- 기준 모델에서 공격 사진의 종료 점수 차는 평균 25.2~26.4점입니다. 종료 토큰이 1등보다 약 25점 낮게 눌려 있다는 뜻입니다.
- 언어모델을 4비트로 바꾸면 이 차이가 1.5~2.6점 줄어 23.7~24.4점이 됩니다. 0이 되려면 한참 남았습니다.
- 문장 끝 종료 여유는 8비트 -25.0 ~ -21.2, 4비트 -21.6 ~ -12.4입니다. 4비트에서 조금 줄어든 사진이 있지만 여전히 음수라, 종료 토큰이 1등이 되지 못합니다.

왜 그런가 (해석)

- 공격 신호가 손상 없이 언어모델까지 도착합니다. 열쇠가 깎인 모양 그대로 자물쇠 앞까지 온 셈입니다.
- 공격은 종료 토큰을 약 25점이나 뒤처지게 만들어 놓았습니다. 반면 정상적인 문장의 끝은 +0.5 ~ +3.0점 차이로 결정됩니다. 25점 차로 이기고 있는 경기에서 심판이 1~3점을 잘못 세어도 승패가 바뀌지 않는 것과 같습니다.
- 비전 인코더에서는 '정밀하게 맞춘 노이즈의 효과' 자체가 흐트러졌지만, 언어모델은 이미 만들어진 강한 신호를 받아서 처리합니다. 그래서 계산이 조금 부정확해져도 결론이 같습니다.

> **결론** 언어모델은 4비트로 양자화해도 공격이 통합니다. 공격 신호가 온전히 도착하고, 종료를 누르는 힘에 여유가 커서 4비트 오차로는 뒤집히지 않기 때문으로 보입니다.

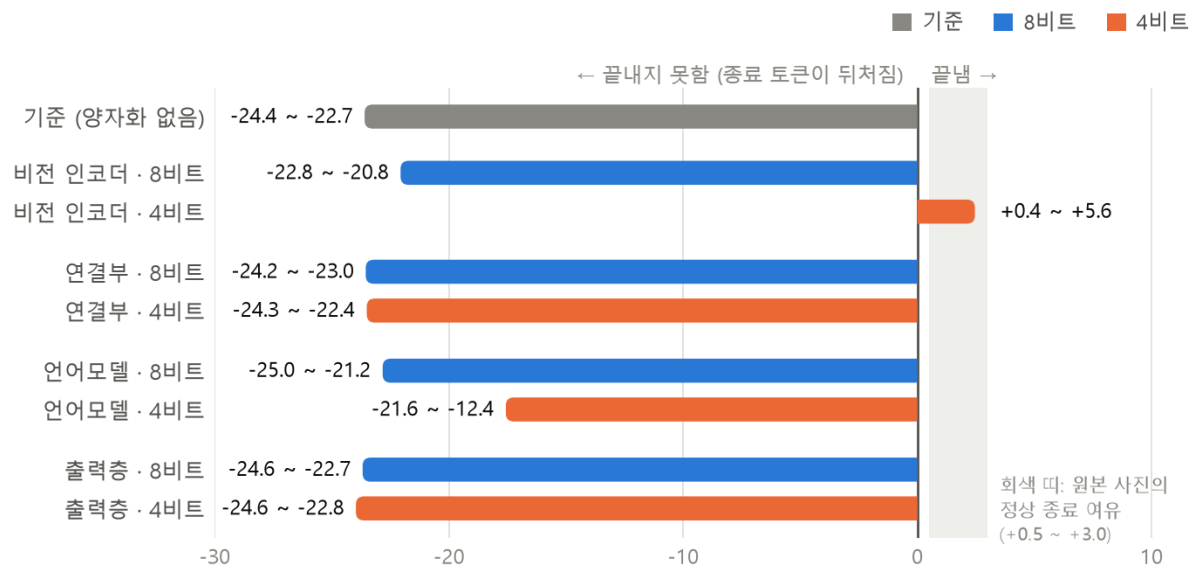


그림 3. 공격 사진에서 문장이 끝난 자리의 종료 여유. 0보다 오른쪽이면 그 자리에서 답을 끝내고, 왼쪽이면 끝내지 못합니다. 막대는 사진 3장의 평균, 숫자는 3장의 범위입니다.

4.4 출력층 — 토큰을 고르는 '입'

사진	기준 (양자화 없음)	출력층만 8비트	출력층만 4비트
곰	10 → 512	10 → 512	10 → 512
고양이	13 → 512	13 → 512	21 → 512
거실	17 → 512	32 → 512	45 → 512
공격 유지	3/3	3/3	3/3

측정으로 확인한 것

- 가중치는 8비트에서 1.23%, 4비트에서 10.81% 달라졌습니다. 네 부분 중 가장 많이 바뀌었습니다.
- 그런데도 공격 사진의 종료 점수 차는 4비트에서 25.8~26.6점으로 기준(25.2~26.4점)과 같고, 문장 끝 종료 여유도 -24.6 ~ -22.8로 기준과 같습니다.
- 대신 **원본 사진**의 답이 길어진 사진이 있습니다. 거실은 17 → 32(8비트) → 45(4비트)토큰, 고양이는 4비트에서 13 → 21토큰입니다. 상한에는 닿지 않았습니다.

- 원본 사진의 정상 종료 여유는 기준에서 +3.0 / +0.5 / +1.0(곰 / 고양이 / 거실)인데, 출력층 4비트에서는 +2.2 / -0.4 / +0.1로 세 장 모두 줄었고 고양이는 음수가 됐습니다.

왜 그런가 (해석)

- 출력층은 토큰마다 점수를 매기는 마지막 계산 한 번입니다. 4비트로 반올림하면 점수가 조금씩 흔들리지만, 위 측정에서 그 크기는 1점 안팎이었습니다.
- 공격 사진에서는 종료 토큰이 약 25점 뒤처져 있어서, 1점 안팎의 흔들림으로는 아무것도 바뀌지 않습니다.
- 원본 사진에서는 사정이 다릅니다. 정상적인 문장의 끝은 종료 토큰이 +0.5 ~ +3.0점 차이로 겨우 이기는 자리입니다. 이런 접전은 1점 안팎의 흔들림으로도 뒤집힐 수 있고, 뒤집히면 답이 더 이어집니다. 고양이 사진이 그런 경우입니다.
- 거실 사진은 문장 끝이 아니라 문장 중간의 단어 선택이 달라져 다른 문장이 된 경우입니다. 이것도 근소한 차이로 결정되던 자리가 바뀐 것으로 보이지만, 따로 재지는 않았습니다.

> **결론** 출력층을 양자화해도 공격은 약해지지 않습니다. 대신 근소한 차이로 결정되는 자리만 영향을 받아, 공격이 없는 정상 사진의 답 길이가 조금 달라집니다.

5. 8비트와 4비트는 무엇이 다른가

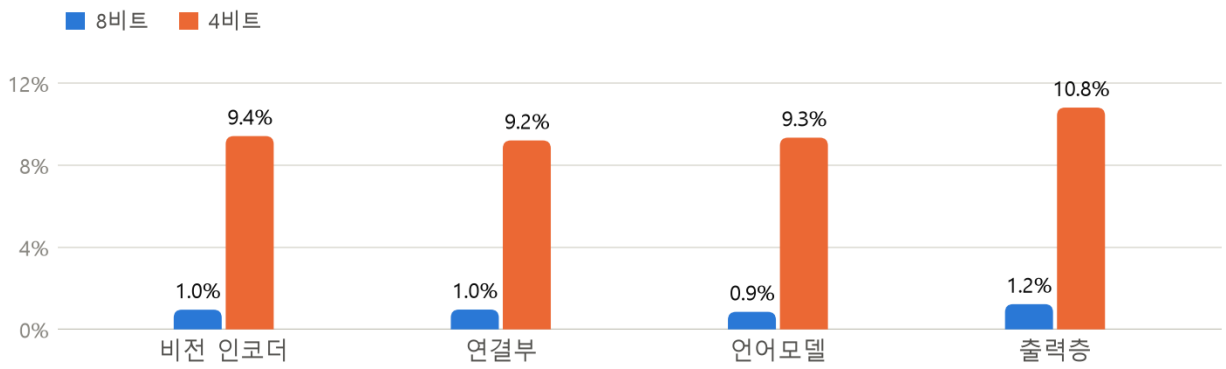


그림 4. 양자화가 가중치를 바꾼 크기(변한 크기 ÷ 원래 크기).

- 8비트는 어느 부분이든 가중치를 0.85~1.23% 바꾸고, 4비트는 9.21~10.81% 바꿉니다. 약 10배 차이입니다.
- **8비트**에서는 모든 측정값이 기준과 거의 같았습니다. 반올림이 너무 촘촘해서 공격에 영향을 주지 못한 것으로 보입니다. 그래서 어느 부분을 바꿔도 공격이 유지됐습니다.
- **4비트**는 변화가 약 10배 큽니다. 그런데 바뀌는 크기는 네 부분이 거의 같은데도, 결과가 달라진 것은 비전 인코더뿐이었습니다.
- 따라서 결과를 정한 것은 '몇 비트인가' 하나가 아닙니다. **'몇 비트인가'와 '어느 부분인가'가 함께** 정했습니다. 4비트이면서, 공격 노이즈가 지나가는 부분일 때만 공격이 약해졌습니다.

6. 그 밖의 이유와 주의할 점

- **사진을 처음 받는 층은 양자화되지 않았습니다.** 비전 인코더의 맨 앞에는 픽셀을 직접 받는 Conv 층이 있는데, 이번에 쓴 도구(bitsandbytes)는 Linear 층만 양자화합니다. 그래서 노이즈는 모델에 들어가는 순간에는 그대로이고, 어긋남은 그 뒤의 72개 층에서 생깁니다.

- **4비트 방식은 한 가지만 썼습니다.** 이번 4비트는 nf4라는 방식입니다. 다른 4비트 방식이나 3비트에서는 결과가 다를 수 있습니다.
- **비전 인코더 4비트의 '약해짐'이 진짜 방어인지는 모릅니다.** 원본 모델에 맞춘 노이즈가 어긋났을 뿐일 수 있습니다. 공격자가 4비트 모델에 맞춰 노이즈를 새로 만들면 다시 통할 수 있고, 이것은 아직 확인하지 않았습니다.
- **4비트에서도 공격의 영향이 일부 남았습니다.** 답이 원본 사진보다 길었고(26, 24, 101토큰 대 10, 13, 18토큰), 사진에 없는 내용이 섞였습니다.
- **사진 3장, 질문 1개의 결과입니다.** 사진을 늘리면 비율이 달라질 수 있습니다. 또 512은 상한이라, 그보다 얼마나 더 길어지는지는 알 수 없습니다.
- **공격 사진은 고정해서 썼습니다.** 같은 컴퓨터에서 다시 만들어도 조금 다른 사진이 나오기 때문에, 한 번 만든 3장을 모든 경우에 그대로 썼습니다.
- **종료 점수 관련 값은 '정해진 문장을 따라가게 했을 때'의 값입니다.** 원인의 방향을 보여 주는 근거이지, 모델이 스스로 답을 만드는 과정 전체를 대신하지는 않습니다.

7. 최종 결론

부분	8비트	4비트	이유 (해석)
비전 인코더	3/3 유지	0/3 약해짐	공격 노이즈가 지나가는 곳. 4비트 오차가 72개 층에 쌓여 공격의 효과가 흐트러짐
연결부	3/3 유지	3/3 유지	층이 하나라 오차가 쌓이지 않음. 공격 신호가 거의 그대로 지나감
언어모델	3/3 유지	3/3 유지	공격 신호가 온전히 도착함. 종료를 누르는 힘(약 25점)에 비해 오차가 작음
출력층	3/3 유지	3/3 유지	점수 흔들림이 1점 안팎. 공격은 그대로이고, 정상 사진의 답 길이만 조금 달라짐

- 원본 모델로 만든 공격은 8비트 양자화 모델에 그대로 통했고, 4비트에서는 비전 인코더를 양자화했을 때만 약해졌습니다. 4비트의 큰 반올림과, 공격 노이즈가 지나가는 자리라는 두 조건이 겹쳤기 때문으로 보입니다.
- 언어모델과 출력층은 답을 직접 만드는 부분이지만, 이 부분을 양자화하는 것으로는 공격을 막지 못했습니다. 양자화만으로 정상 사진의 답이 512토큰까지 길어진 경우도 없었습니다.

다음에 확인할 것

- 사진을 30~100장으로 늘려 같은 실험을 되풀이하고, 3/3과 0/3이 비율로도 유지되는지 봅니다.
- 비전 인코더 4비트 모델을 직접 공격해 봅니다. 그래도 공격이 약하면 진짜 방어이고, 다시 통하면 노이즈가 어긋났던 것뿐입니다.
- 두 부분 이상을 함께 양자화하거나 전체를 양자화한 경우를 같은 방법으로 잽니다. 실제 기기에는 전체를 양자화한 모델이 들어가기 때문입니다.
- 맥(MLX)에서 3비트와 에너지를 잽니다. 이번 결과는 답 길이만 본 것입니다.

부록 A. 답 길이 전체 (원본 사진 → 공격 사진, 토큰)

경우	곰	고양이	거실	공격 유지
기준 (양자화 없음)	10 → 512	13 → 512	17 → 512	3/3
비전 인코더만 8비트	10 → 512	13 → 512	19 → 512	3/3
비전 인코더만 4비트	10 → 26	13 → 24	18 → 101	0/3
연결부만 8비트	10 → 512	13 → 512	22 → 512	3/3
연결부만 4비트	10 → 512	13 → 512	17 → 512	3/3
언어모델만 8비트	10 → 512	13 → 512	29 → 512	3/3
언어모델만 4비트	13 → 512	10 → 512	17 → 512	3/3
출력층만 8비트	10 → 512	13 → 512	32 → 512	3/3
출력층만 4비트	10 → 512	21 → 512	45 → 512	3/3

곰 사진의 파일 이름은 bus.jpg입니다. 내려받을 때 이름을 잘못 붙인 것이고, 실제 사진은 곰입니다.

부록 B. 원인 측정값 전체 (곰 / 고양이 / 거실)

경우	가중치 변화	공격 방향 보존	흔들림 비율
기준 (양자화 없음)	0.00%	1.00 / 1.00 / 1.00	0.00 / 0.00 / 0.00
비전 인코더만 8비트	0.96%	0.99 / 0.98 / 0.98	0.15 / 0.15 / 0.15
비전 인코더만 4비트	9.42%	0.81 / 0.74 / 0.76	0.61 / 0.63 / 0.61
연결부만 8비트	0.97%	1.00 / 1.00 / 1.00	0.01 / 0.01 / 0.01
연결부만 4비트	9.21%	1.00 / 1.00 / 1.00	0.07 / 0.07 / 0.07
언어모델만 8비트	0.85%	1.00 / 1.00 / 1.00	0.00 / 0.00 / 0.00
언어모델만 4비트	9.35%	1.00 / 1.00 / 1.00	0.00 / 0.00 / 0.00
출력층만 8비트	1.23%	1.00 / 1.00 / 1.00	0.00 / 0.00 / 0.00
출력층만 4비트	10.81%	1.00 / 1.00 / 1.00	0.00 / 0.00 / 0.00

경우	종료 점수 차 (평균)	문장 끝 종료 여유 (공격 사진)	정상 종료 여유 (원본 사진)	자기 답 기준 종료 점수 차
기준 (양자화 없음)	25.2 / 26.4 / 26.2	-23.7 / -24.4 / -22.7	+3.0 / +0.5 / +1.0	25.8 / 25.5 / 25.0
비전 인코더만 8비트	25.0 / 25.4 / 25.4	-22.6 / -22.8 / -20.8	+3.0 / +0.5 / +1.2	26.4 / 24.7 / 24.3
비전 인코더만 4비트	18.8 / 18.5 / 18.6	+1.4 / +5.6 / +0.4	+2.9 / +2.0 / +0.9	21.7 / 23.4 / 18.3
연결부만 8비트	25.2 / 26.4 / 26.3	-23.5 / -24.2 / -23.0	+3.0 / +0.4 / +1.0	25.9 / 24.8 / 26.0
연결부만 4비트	25.2 / 26.1 / 26.1	-23.8 / -24.3 / -22.4	+3.0 / +0.6 / +0.9	25.7 / 26.2 / 24.9
언어모델만 8비트	24.8 / 26.2 / 26.6	-22.3 / -25.0 / -21.2	+2.8 / +0.9 / +1.8	26.5 / 25.6 / 25.7
언어모델만 4비트	23.7 / 23.8 / 24.4	-18.7 / -21.6 / -12.4	+5.2 / +1.4 / +0.9	25.9 / 23.7 / 23.5
출력층만 8비트	25.3 / 26.4 / 26.2	-23.8 / -24.6 / -22.7	+3.1 / +0.4 / +1.0	25.8 / 26.3 / 24.9
출력층만 4비트	25.8 / 26.2 / 26.6	-24.6 / -24.5 / -22.8	+2.2 / -0.4 / +0.1	26.6 / 24.9 / 26.3

자기 답 기준 종료 점수 차는 각 모델이 공격 사진에 스스로 낸 답의 앞 16토큰에서 잰 평균입니다. 문장 중간에서는 어느 모델이든 종료 토큰의 점수가 낮아서, 비전 인코더만 4비트(18.3~23.4)도 기준(25.0~25.8)과 큰 차이가 나지 않았습니다. 답이 끝나는지는 문장이 끝나는 자리에서 갈렸습니다.

부록 C. 용어 풀이

용어	뜻
토큰	모델이 글을 다루는 단위. 단어 하나이거나 단어의 조각입니다.
종료 토큰	'답이 여기서 끝난다'는 뜻의 특별한 토큰. 이 토큰이 1등으로 뽑히면 답이 끝납니다.
가중치	모델을 이루는 숫자들. 모델이 배운 내용이 이 숫자에 담겨 있습니다.
양자화	가중치를 적은 수의 정해진 값으로 반올림해 모델 용량을 줄이는 방법.
8비트 / 4비트	반올림에 쓰는 값의 개수. 8비트는 256개, 4비트는 16개입니다.
bf16	양자화하지 않은 원본 모델의 숫자 형식. 이 문서의 '기준'입니다.
Linear 층	숫자 여러 개를 곱하고 더하는 계산 한 번. 이번 실험에서 양자화한 대상입니다.
그림 정보	비전 인코더와 연결부를 거쳐 언어모델로 들어가는, 사진을 나타내는 숫자 묶음.
전이	한 모델(원본)로 만든 공격이 다른 모델(양자화 모델)에서도 통하는 것.

이 문서의 표와 그림은 results 폴더의 2~6번 CSV에서 만들었습니다. 측정 방법은 같은 번호의 노트북에 있습니다.